




PROYECTO FINAL

Diseño e Implementación de un Data Pipeline con AWS.

DESCRIPCIÓN BREVE

Diseño e implementación de un pipeline de datos completo que permite transformar un dataset desde su formato original hasta un formato optimizado para consultas analítica mediante Amazon Athena

Abel Gijón Cordero

Big Data Aplicado

Índice

1	Introducción	3
1.1	Problema o caso de uso.....	3
1.2	Objetivo del análisis.....	3
2	Análisis de los datasets	4
2.1	Descripción de los datos.....	4
2.1.1	Dataset principal: Spotify 1.2M Songs	4
2.1.2	Dataset secundario: Grammy Award Nominees and Winners (1958–2024).....	5
2.1.3	Dataset secundario: BRIT Awards (1982–2025).....	6
2.1.4	Dataset secundario: Billboard Winners (1997–2022)	6
2.1.5	Integración de datasets.....	7
2.2	Calidad de los datos.....	7
2.3	Limitaciones.....	8
3	Diseño de la arquitectura	9
3.1	Diagrama del pipeline de datos.....	9
3.2	Explicación de cada componente	9
3.2.1	Datasets de entrada	9
3.2.2	Scripts Python + Boto3	9
3.2.3	Amazon S3 – Capa raw	9
3.2.4	Scripts de limpieza y normalización	10
3.2.5	Amazon S3 – Capa clean	10
3.2.6	AWS Glue Job	10
3.2.7	Amazon S3 – Capa processed.....	10
3.2.8	AWS Glue Crawler	11
3.2.9	AWS Glue Data Catalog.....	11
3.2.10	Amazon Athena	11
4	Proceso ETL	12
4.1	Explicación de los scripts	12
4.1.1	Scripts de carga a raw	12
4.1.2	Scripts de limpieza y normalización	12
4.1.3	AWS Glue Job para integración final.....	13
4.2	Formato elegido y justificación	13
4.2.1	CSV como formato de entrada.....	13
4.2.2	Parquet como formato de salida	13
5	Data Lake en S3	14

5.1	Estructura de almacenamiento	14
5.1.1	Capa raw (datos en bruto)	14
5.1.2	Capa clean (datos limpios)	14
5.1.3	Capa processed (dataset analítico)	15
5.2	Justificación de la estructura	15
6	Catalogación de datos	16
6.1	Crawler de AWS Glue	16
6.2	Tabla generada	16
7	Análisis en Athena	18
7.1	Consultas SQL	18
7.1.1	Consulta 1. Comparación entre canciones premiadas y no premiadas	18
7.1.2	Consulta 2. Evolución temporal de las características musicales	19
7.1.3	Consulta 3. Comparativa entre la duración media	20
7.2	Explicación de resultados	21
7.2.1	Interpretación de la Consulta 1.....	21
7.2.2	Interpretación de la Consulta 2.....	21
7.2.3	Interpretación de la Consulta 3.....	21
8	Conclusiones	23
8.1	Hallazgos principales	23
8.2	Posibles mejoras del pipeline	23

1 INTRODUCCIÓN

En la actualidad, la industria musical genera grandes volúmenes de datos procedentes de múltiples fuentes, como plataformas de streaming y sistemas de premios musicales. Sin embargo, estos datos suelen encontrarse distribuidos en distintos formatos y estructuras, lo que dificulta su explotación conjunta para realizar análisis más completos.

1.1 PROBLEMA O CASO DE USO

El principal problema abordado en este proyecto es la fragmentación de la información musical. Por un lado, existen datasets como Spotify que contienen características técnicas de las canciones (energía, danceability, valence, etc.), y por otro, datasets independientes que recogen información sobre premios musicales como los Grammy, BRIT o Billboard.

La falta de integración entre estas fuentes impide responder a preguntas relevantes como:

- ¿Qué características tienen las canciones premiadas?
- ¿Existe relación entre el éxito comercial y el reconocimiento en premios?
- ¿Cómo han evolucionado las características musicales a lo largo del tiempo?

Además, trabajar directamente con archivos CSV de gran tamaño no es eficiente para consultas analíticas, lo que hace necesario diseñar una solución que permita almacenar, transformar y consultar los datos de forma escalable.

1.2 OBJETIVO DEL ANÁLISIS

El objetivo principal de este proyecto es diseñar e implementar un pipeline de datos completo en AWS que permita:

- Integrar múltiples datasets musicales en una única estructura unificada.
- Limpiar y normalizar los datos para garantizar su calidad.
- Transformar los datos a un formato optimizado para análisis (Parquet).
- Permitir la consulta eficiente mediante herramientas analíticas como Amazon Athena.

A partir de este pipeline, se busca obtener insights relevantes sobre la industria musical, tales como:

- Identificar patrones en las características de las canciones premiadas.
- Analizar la evolución de atributos musicales a lo largo del tiempo.
- Estudiar la relación entre popularidad en plataformas digitales y reconocimiento en premios.

En definitiva, el proyecto pretende demostrar cómo una arquitectura basada en Data Lake permite transformar datos heterogéneos en información útil para la toma de decisiones y el análisis avanzado.

2 ANÁLISIS DE LOS DATASETS

En este apartado se analizan los datasets utilizados en el proyecto desde el punto de vista de su estructura, calidad y limitaciones. Este análisis es clave para definir las transformaciones necesarias en el proceso ETL y garantizar una correcta integración de los datos.

2.1 DESCRIPCIÓN DE LOS DATOS

El proyecto utiliza un conjunto de datasets complementarios:

2.1.1 Dataset principal: Spotify 1.2M Songs

Fuente.

El dataset lo tenemos descargado en .csv en una de las carpetas de nuestro equipo.

<https://www.kaggle.com/datasets/rodolfofigueroa/spotify-12m-songs>

Descripción del dataset.

Este dataset contiene información sobre más de 1,2 millones de canciones disponibles en Spotify, incluyendo metadatos de las canciones y características acústicas extraídas mediante la API de Spotify.

El objetivo del dataset es permitir el análisis masivo de características musicales, tendencias en la industria musical y comportamiento de los estilos musicales a lo largo del tiempo.

Origen de los datos.

Los datos han sido recopilados utilizando la Spotify Web API, que proporciona información sobre pistas, artistas, álbumes y atributos musicales calculados automáticamente.

Tipo de información contenida.

El dataset contiene aproximadamente 1,2 millones de registros con 24 variables cada uno. Las características que aporta principalmente son:

- Metadatos de la canción.
 - Nombre de la canción
 - Artista
 - Álbum
 - Fecha de lanzamiento
 - Duración
 - Popularidad
- Características musicales (audio features)
 - Danceability
 - Energy
 - Loudness
 - Tempo
 - Valence (nivel de positividad de la canción)
 - Acousticness
 - Instrumentalness
 - Liveness

Estas características permiten analizar matemáticamente las propiedades musicales de cada canción.

Posibles problemas de calidad de datos.

1. Duplicados.
Las canciones podrían estar repetidas por diferentes versiones o remixes.
2. Datos incompletos.
Algunas canciones pueden no tener todos los atributos musicales.
3. Inconsistencia en nombres.
Artistas y canciones pueden aparecer con variantes.
4. Datos sesgados.
Spotify contiene principalmente música moderna, lo que puede afectar a los análisis históricos.

2.1.2 Dataset secundario: Grammy Award Nominees and Winners (1958–2024)

Fuente.

El dataset lo tenemos almacenado en una de las carpetas de nuestro equipo.

<https://www.kaggle.com/datasets/kfoster150/grammy-award-nominees-and-winners-1958-2024>

Descripción del dataset.

Este dataset contiene información histórica sobre nominados y ganadores de los premios Grammy, uno de los premios más importantes de la industria musical.

Los Grammy Awards son premios otorgados desde 1959 por la National Academy of Recording Arts and Sciences para reconocer excelencia artística en la industria musical.

Origen de los datos.

Los datos se obtienen a partir de registros históricos de los premios Grammy, recopilados y estructurados en Kaggle.

Tipo de información contenida.

El dataset contiene alrededor de 25000 registros con 9 variables cada uno. Las características que aporta son:

- Año del premio.
- Categoría.
- Artista.
- Canción o álbum.
- Indicación de ganador o nominado.
- Tipo de obra (canción/álbum).

Posibles problemas de calidad de datos.

1. Cambios en categorías.
Las categorías de los Grammys cambian con el tiempo.
2. Inconsistencia en nombres.
Diferentes formatos para artistas o canciones.

3. Datos incompletos en años antiguos.

2.1.3 Dataset secundario: BRIT Awards (1982–2025)

Fuente.

El dataset lo tenemos descargado en .csv en una de las carpetas de nuestro equipo.

<https://www.kaggle.com/datasets/johnpendenque/brit-awards-from-1982-to-2025>

Descripción del dataset.

Contiene información sobre los premios BRIT, uno de los premios musicales más importantes del Reino Unido. Incluye información sobre ganadores y nominados desde 1982 hasta 2025.

Origen de los datos.

Datos recopilados a partir de registros históricos de los BRIT Awards y compilados en Kaggle.

Tipo de información contenida.

El dataset contiene alrededor de 650 registros con 9 variables cada uno. Las características que aporta son:

- Año.
- Categoría.
- Artista.
- Obra premiada.
- Ganador / Nominado.

Posibles problemas en calidad de datos.

1. Cambios en categorías con el tiempo.
2. Inconsistencia en nombre de artistas.
3. Diferencias entre artistas individuales y grupos.

2.1.4 Dataset secundario: Billboard Winners (1997–2022)

Fuente.

El dataset lo tenemos descargado en .csv en una de las carpetas de nuestro equipo.

<https://www.kaggle.com/datasets/johnpendenque/billboard-winners-1997-2022>

Descripción del dataset.

Este dataset contiene información sobre los ganadores de los Billboard Music Awards, premios que reconocen a artistas según su rendimiento en las listas musicales.

Origen de los datos.

Datos obtenidos de registros históricos de los Billboard Music Awards y compilados en Kaggle.

Tipo de información contenida.

El dataset contiene alrededor de 1000 registros con 4 variables cada uno. Las características que aporta son:

- Año
- Categoría
- Ganador
- Canción

Posibles problemas de calidad de datos.

1. Cambios en categorías.
2. Datos incompletos en algunos años.
3. Artistas con nombres inconsistentes.

2.1.5 Integración de datasets

Estos datasets contienen información heterogénea que incluye:

- Metadatos (artista, canción, álbum, año)
- Características musicales
- Información de premios (categoría, ganador, tipo de obra)

La integración de estos datos permite enriquecer el dataset de Spotify con información sobre reconocimiento en la industria musical.

Permiten realizar análisis combinados, por ejemplo:

1. Relación entre características musicales y premios.
¿Las canciones con mayor danceability ganan más premios?
2. Éxito comercial vs reconocimiento
¿Las canciones populares en Spotify ganan premios?
3. Comparación entre premios.
Grammy vs Brit vs Billboard
4. Evolución musical.
Cambios en tempo, energía o valence de las canciones premiadas.
5. Perfil de canciones ganadoras
Identificar características comunes entre canciones premiadas

2.2 CALIDAD DE LOS DATOS

Durante el análisis inicial se identificaron varios problemas de calidad de datos:

- **Valores nulos** en algunas métricas musicales.
- **Duplicados** en canciones debido a versiones o remixes.
- **Inconsistencias en nombres** de artistas y canciones (mayúsculas, caracteres especiales, variaciones).
- **Estructuras distintas** entre datasets (columnas diferentes y formatos no homogéneos).

Para resolver estos problemas, se aplicaron las siguientes acciones en el proceso ETL:

- Normalización de texto (minúsculas, eliminación de caracteres especiales).
- Creación de campos estandarizados (artist_clean, track_clean).

- Conversión de tipos de datos.
- Tratamiento de valores nulos.

Estas transformaciones permiten mejorar la calidad de los datos y asegurar una correcta integración entre fuentes.

2.3 LIMITACIONES

A pesar del proceso de limpieza y normalización, el proyecto presenta algunas limitaciones inherentes a los datos:

- **Dependencia de coincidencias textuales:** la integración entre datasets se basa en nombres de artistas y canciones, lo que puede generar errores en algunos cruces.
- **Cambios en categorías de premios** a lo largo del tiempo, lo que dificulta comparaciones históricas.
- **Sesgo temporal en Spotify**, ya que contiene mayor cantidad de datos recientes.
- **Datos incompletos en años antiguos** en algunos datasets de premios.
- **Valores nulos o inválidos en la columna year:** en algunos registros el año no está disponible o presenta valores incorrectos, lo que puede generar particiones no deseadas (por ejemplo, year=0) durante el procesamiento. Esto puede afectar a los análisis temporales y requiere filtrado o tratamiento específico en las consultas.


Estas limitaciones deben tenerse en cuenta a la hora de interpretar los resultados analíticos obtenidos.

3 DISEÑO DE LA ARQUITECTURA

En este apartado se describe la arquitectura del pipeline de datos implementado en AWS, así como la función de cada uno de sus componentes. El diseño sigue un enfoque de tipo Data Lake, en el que los datos pasan por distintas capas hasta convertirse en un dataset analítico optimizado para su consulta.

3.1 DIAGRAMA DEL PIPELINE DE DATOS

El flujo general del pipeline puede representarse de la siguiente manera:



Este pipeline refleja el paso completo desde los datos originales en formato CSV hasta su explotación analítica mediante consultas SQL sobre S3.

3.2 EXPLICACIÓN DE CADA COMPONENTE

3.2.1 Datasets de entrada

El pipeline parte de cuatro datasets descargados en formato CSV: Spotify, Grammys, BRIT Awards y Billboard Winners. Cada uno aporta una parte distinta de la información, combinando características musicales, metadatos y datos de premios.

3.2.2 Scripts Python + Boto3

La primera fase del pipeline se realiza mediante scripts en Python que utilizan la librería Boto3. Estos scripts automatizan la carga de los datasets desde el entorno local al bucket de Amazon S3, evitando un proceso manual y permitiendo la repetición del flujo cuando sea necesario.

3.2.3 Amazon S3 – Capa raw

La capa raw del Data Lake almacena los archivos originales sin modificaciones. Su objetivo es conservar una copia fiel de las fuentes de datos y servir como punto de partida del pipeline.

Estructura utilizada:

- s3://datalake-agijonc-2026/raw/spotify/
- s3://datalake-agijonc-2026/raw/grammys/
- s3://datalake-agijonc-2026/raw/brits/
- s3://datalake-agijonc-2026/raw/billboard/

3.2.4 Scripts de limpieza y normalización

Una vez cargados los archivos en la capa raw, se ejecutan scripts en Python para limpiar y normalizar cada dataset de forma independiente. Esta fase incluye la estandarización de nombres de columnas, la normalización de texto, el tratamiento de valores nulos y la creación de campos auxiliares como `artist_clean` y `track_clean`.

3.2.5 Amazon S3 – Capa clean

La capa clean almacena los datasets ya depurados y preparados para su integración. Esta capa permite trabajar con datos normalizados sin necesidad de repetir el proceso de limpieza en cada ejecución.

Estructura utilizada:

- s3://datalake-agijonc-2026/clean/spotify/
- s3://datalake-agijonc-2026/clean/grammys/
- s3://datalake-agijonc-2026/clean/brits/
- s3://datalake-agijonc-2026/clean/billboard/

3.2.6 AWS Glue Job

El componente central del pipeline es un AWS Glue Job, encargado de leer los datasets limpios desde la capa clean, realizar los cruces necesarios y generar el dataset analítico final.

En esta etapa, el dataset de Spotify se utiliza como base principal y se enriquece con información procedente de Grammys, BRITs y Billboard. La integración se realiza principalmente mediante las columnas normalizadas `artist_clean`, `track_clean` y `year`.

3.2.7 Amazon S3 – Capa processed

La capa processed almacena el resultado final del pipeline. Este dataset se guarda en formato Parquet, optimizado para consultas analíticas, y se organiza mediante particiones por año.

Estructura esperada:

- s3://datalake-agijonc-2026/processed/year=1997/
- s3://datalake-agijonc-2026/processed/year=1998/
- s3://datalake-agijonc-2026/processed/year=1999/

Esta organización permite mejorar el rendimiento en Athena y reducir el volumen de datos escaneados.

3.2.8 AWS Glue Crawler

Una vez generado el dataset final, un AWS Glue Crawler analiza automáticamente la carpeta processed/, detecta el esquema de los datos y las particiones por año, y registra esta información en el catálogo de Glue.

3.2.9 AWS Glue Data Catalog

El Glue Data Catalog actúa como repositorio de metadatos. Gracias a él, Amazon Athena puede acceder a la estructura lógica del dataset sin necesidad de definir manualmente las tablas.

3.2.10 Amazon Athena

Finalmente, Amazon Athena permite ejecutar consultas SQL directamente sobre los archivos Parquet almacenados en S3. Esta herramienta constituye la capa analítica final del proyecto y es la encargada de extraer insights y responder a las preguntas planteadas en el análisis.

4 PROCESO ETL

En este apartado se describe el proceso ETL aplicado en el proyecto, desde la carga inicial de los datasets en la capa raw hasta la generación del dataset analítico final en la capa processed. El objetivo de esta fase es transformar archivos heterogéneos en una estructura homogénea, limpia y optimizada para su explotación analítica.

4.1 EXPLICACIÓN DE LOS SCRIPTS

El proceso ETL se implementa mediante una combinación de scripts en Python y un AWS Glue Job. Cada etapa tiene una función concreta dentro del pipeline.

4.1.1 Scripts de carga a raw

La primera parte del proceso consiste en la subida de los datasets originales en formato CSV a la capa raw del Data Lake. Para ello se utilizan scripts en Python con la librería Boto3, encargados de conectarse a Amazon S3 y cargar cada fichero en su ruta correspondiente.

Esta automatización permite:

- Evitar la carga manual de archivos.
- Mantener una estructura consistente dentro del bucket.
- Repetir el proceso de forma sencilla si es necesario volver a cargar los datos.

4.1.2 Scripts de limpieza y normalización

Una vez almacenados los archivos en la capa raw, se ejecutan scripts de limpieza específicos para cada dataset. Aunque cada fuente presenta características distintas, el proceso sigue una lógica común.

Las transformaciones más importantes son:

- Estandarización de nombres de columnas.
- Conversión de texto a minúsculas.
- Eliminación de caracteres especiales y espacios redundantes.
- Tratamiento de valores nulos.
- Eliminación de columnas irrelevantes para el análisis final.
- Conversión de tipos de datos.
- Generación de campos auxiliares normalizados como `artist_clean` y `track_clean`.

En el caso del dataset de Spotify, además, se rellenan los valores nulos de algunas métricas numéricas utilizando la media de la columna correspondiente. En los datasets de premios, se limpian los nombres de artistas, categorías y obras para facilitar la integración posterior.

El resultado de esta fase se almacena en la capa clean en formato Parquet.

4.1.3 AWS Glue Job para integración final

Una vez disponibles los datasets limpios, un AWS Glue Job se encarga de realizar la integración final. Este proceso toma como base el dataset de Spotify y lo enriquece con información procedente de Grammys, BRITs y Billboard.

La integración se apoya en las columnas normalizadas:

- artist_clean
- track_clean
- year

A partir de estas claves se generan nuevas variables relacionadas con premios, nominaciones y presencia del artista o la canción en los diferentes datasets secundarios.

El resultado final se escribe en la capa processed, organizada mediante particiones por año.

4.2 FORMATO ELEGIDO Y JUSTIFICACIÓN

A lo largo del pipeline se utilizan dos formatos principales: CSV y Parquet.

4.2.1 CSV como formato de entrada

Los datasets originales se encuentran en formato CSV, un formato ampliamente utilizado para intercambio de datos por su sencillez y compatibilidad. Este formato resulta adecuado como punto de partida, pero presenta limitaciones cuando se trabaja con grandes volúmenes de información, especialmente en términos de rendimiento y consumo de almacenamiento.

4.2.2 Parquet como formato de salida

Tras el proceso de limpieza y transformación, los datos se almacenan en formato Parquet tanto en la capa clean como en la capa processed.

La elección de Parquet se justifica por varias razones:

- Es un formato columnar, lo que mejora la eficiencia en la lectura de datos.
- Reduce el tamaño de almacenamiento frente a CSV.
- Mejora el rendimiento de las consultas analíticas.
- Disminuye el volumen de datos escaneados por Amazon Athena, reduciendo así el coste de consulta.
- Se integra de forma nativa con servicios de AWS como Glue y Athena.

Además, en la capa processed el dataset se organiza mediante particiones por año, lo que permite que las consultas temporales lean únicamente las particiones necesarias.

En conjunto, la combinación de Parquet y particionado por year constituye una decisión técnica clave para optimizar el pipeline y hacer viable el análisis eficiente sobre grandes volúmenes de datos.

5 DATA LAKE EN S3

En este apartado se describe la organización del Data Lake implementado en Amazon S3. La estructura sigue un enfoque por capas que permite separar los datos según su nivel de procesamiento, facilitando la trazabilidad, reutilización y eficiencia en el análisis.

5.1 ESTRUCTURA DE ALMACENAMIENTO

El bucket principal utilizado en el proyecto es:

- `s3://datalake-agijonc-2026/`

Dentro de este bucket, los datos se organizan en tres capas principales:

5.1.1 Capa raw (datos en bruto)

Contiene los archivos originales tal y como se descargan desde Kaggle, sin ningún tipo de transformación.

Estructura:

- `s3://datalake-agijonc-2026/raw/spotify/`
- `s3://datalake-agijonc-2026/raw/grammys/`
- `s3://datalake-agijonc-2026/raw/brits/`
- `s3://datalake-agijonc-2026/raw/billboard/`

Características:

- Formato CSV
- Sin modificaciones
- Permite reproducibilidad del pipeline

5.1.2 Capa clean (datos limpios)

Contiene los datasets una vez aplicadas las transformaciones de limpieza y normalización.

Estructura:

- `s3://datalake-agijonc-2026/clean/spotify/`
- `s3://datalake-agijonc-2026/clean/grammys/`
- `s3://datalake-agijonc-2026/clean/brits/`
- `s3://datalake-agijonc-2026/clean/billboard/`

Características:

- Formato Parquet
- Datos normalizados
- Columnas estandarizadas (artist_clean, track_clean, year)

- Eliminación de columnas innecesarias

Esta capa permite reutilizar los datos limpios sin necesidad de repetir el proceso de transformación.

5.1.3 Capa processed (dataset analítico)

Contiene el dataset final resultante de la integración de todas las fuentes de datos.

Estructura:

- s3://datalake-agijonc-2026/processed/year=1997/
- s3://datalake-agijonc-2026/processed/year=1998/
- s3://datalake-agijonc-2026/processed/year=1999/

Características:

- Formato Parquet
- Dataset unificado
- Enriquecido con información de premios
- Particionado por year

El particionado por año permite:

- Reducir el volumen de datos escaneados en Athena
- Mejorar el rendimiento de las consultas
- Facilitar análisis temporales

5.2 JUSTIFICACIÓN DE LA ESTRUCTURA

La organización en capas (raw, clean, processed) sigue las mejores prácticas en arquitecturas Data Lake y aporta las siguientes ventajas:

- Trazabilidad: se conserva siempre el dato original.
- Reprocesamiento: permite rehacer transformaciones sin depender de datos externos.
- Separación de responsabilidades: cada capa tiene un propósito claro.
- Optimización de consultas: el dataset final está preparado para análisis eficiente.

Esta estructura facilita la escalabilidad del sistema y permite incorporar nuevas fuentes de datos en el futuro sin modificar el diseño base del pipeline.

6 CATALOGACIÓN DE DATOS

En este apartado se describe el proceso de catalogación de los datos almacenados en la capa processed del Data Lake mediante AWS Glue, así como la generación de la tabla que permite su consulta desde Amazon Athena.

6.1 CRAWLER DE AWS GLUE

Para automatizar la detección del esquema y de las particiones, se utiliza un AWS Glue Crawler configurado sobre la ruta:

- s3://datalake-agijonc-2026/processed/

Configuración principal del crawler:

- Fuente de datos: S3 (ruta processed/)
- Tipo de datos: Parquet
- Rol IAM: rol del laboratorio con permisos sobre S3 y Glue
- Base de datos destino: creada en Glue Data Catalog (por ejemplo, music_datalake_db)

Funcionamiento:

El crawler analiza automáticamente los archivos Parquet, detecta:

- Nombres de columnas
- Tipos de datos
- Particiones (en este caso year)

Y registra esta información en el catálogo de Glue.

Esto permite evitar la definición manual del esquema y facilita la actualización automática si cambian los datos.

6.2 TABLA GENERADA

Como resultado de la ejecución del crawler, se genera una tabla en el AWS Glue Data Catalog, que posteriormente es accesible desde Amazon Athena.

Características de la tabla:

- Ubicación: s3://datalake-agijonc-2026/processed/
- Formato: Parquet
- Particionada por: year
- Columnas: incluyen información de Spotify enriquecida con datos de premios (por ejemplo, artist_name, track_name, danceability, energy, indicadores de premios, etc.)

Gracias a la partición por año, Athena puede ejecutar consultas más eficientes, leyendo únicamente los datos necesarios.

La catalogación constituye un paso fundamental del pipeline, ya que conecta el almacenamiento en S3 con la capa analítica, permitiendo explotar los datos mediante SQL sin necesidad de moverlos a otro sistema.

7 ANÁLISIS EN ATHENA

Una vez catalogado el dataset final generado en la capa processed, se utiliza Amazon Athena como motor de consulta serverless para realizar el análisis final del proyecto. Esta herramienta permite ejecutar sentencias SQL directamente sobre los archivos almacenados en S3, sin necesidad de cargar los datos en una base de datos tradicional.

Para completar el flujo analítico, se propone almacenar los resultados de Athena en una capa específica analytics/ dentro del Data Lake. Esta capa permite separar claramente:

- Los datos transformados para consulta (processed/)
- Los resultados derivados del análisis (analytics/)

De este modo, el Data Lake no solo almacena los datos fuente y el dataset analítico final, sino también los resultados generados por las consultas más relevantes del proyecto. Esta estrategia facilita la trazabilidad, la reutilización de resultados y la posible construcción futura de cuadros de mando o visualizaciones.

7.1 CONSULTAS SQL

Con el objetivo de extraer información relevante del dataset integrado, se han definido varias consultas analíticas orientadas a responder preguntas de negocio sobre la relación entre características musicales y premios.

Para cada análisis se plantea una doble ejecución:

1. Consulta de exploración en Athena, para visualizar el resultado directamente en pantalla.
2. Consulta de persistencia, para guardar el resultado en la capa analytics/ del Data Lake.

Para persistir los resultados en S3 se utiliza el enfoque UNLOAD, que permite exportar el resultado de una consulta directamente a una ruta específica de Amazon S3 sin necesidad de crear una nueva tabla en el catálogo. Este enfoque resulta más adecuado para la capa analytics/, ya que permite conservar los resultados de las consultas en formato Parquet de forma limpia y reutilizable.

A continuación, se presentan cinco consultas SQL representativas del análisis realizado.

7.1.1 Consulta 1. Comparación entre canciones premiadas y no premiadas

Esta consulta permite comparar si las canciones que han recibido algún premio relevante presentan diferencias en sus características musicales frente a las que no han sido premiadas.

Consulta para visualización en Athena:

```
SELECT
  has_any_major_award,
  COUNT(*) AS total_songs,
  AVG(danceability) AS avg_danceability,
  AVG(energy) AS avg_energy,
  AVG(valence) AS avg_valence,
  AVG(tempo) AS avg_tempo
FROM processed
```

```
GROUP BY has_any_major_award;
```

Consulta para guardar el resultado en S3:

```
UNLOAD (
  SELECT
    has_any_major_award,
    COUNT(*) AS total_songs,
    AVG(danceability) AS avg_danceability,
    AVG(energy) AS avg_energy,
    AVG(valence) AS avg_valence,
    AVG(tempo) AS avg_tempo
  FROM processed
  GROUP BY has_any_major_award
)
TO 's3://datalake-agijonc-2026/analytics/query_01/'
WITH (
  format = 'PARQUET'
);
```

7.1.2 Consulta 2. Evolución temporal de las características musicales

Esta consulta analiza cómo han evolucionado las características musicales a lo largo del tiempo. Debido a que la partición year fue interpretada como texto por Athena, se utiliza conversión explícita a entero.

Consulta para visualización en Athena:

```
WITH data AS (
  SELECT
    CAST(year AS INTEGER) AS year,
    danceability,
    energy,
    acousticness,
    valence
  FROM processed
)
SELECT
  year,
  AVG(danceability) AS avg_danceability,
  AVG(energy) AS avg_energy,
  AVG(acousticness) AS avg_acousticness,
  AVG(valence) AS avg_valence,
  COUNT(*) AS total_songs
FROM data
WHERE year >= 1950
GROUP BY year
ORDER BY year;
```

Consulta para guardar el resultado en S3:

```

UNLOAD (
  WITH data AS (
    SELECT
      CAST(year AS INTEGER) AS year,
      danceability,
      energy,
      acousticness,
      valence
    FROM processed
  )
  SELECT
    year,
    AVG(danceability) AS avg_danceability,
    AVG(energy) AS avg_energy,
    AVG(acousticness) AS avg_acousticness,
    AVG(valence) AS avg_valence,
    COUNT(*) AS total_songs
  FROM data
  WHERE year >= 1950
  GROUP BY year
)
TO 's3://datalake-agijonc-2026/analytics/query_02/'
WITH (
  format = 'PARQUET'
);

```

7.1.3 Consulta 3. Comparativa entre la duración media

Esta consulta compara la duración media de las canciones premiadas frente a las no premiadas, con el fin de analizar si existe alguna diferencia significativa en la longitud de las canciones asociadas al reconocimiento musical.

Consulta para visualización en Athena:

```

SELECT
  has_any_major_award,
  COUNT(*) AS total_songs,
  AVG(duration_ms) AS avg_duration_ms,
  ROUND(AVG(duration_ms) / 1000, 2) AS avg_duration_seconds,
  ROUND(AVG(duration_ms) / 60000, 2) AS avg_duration_minutes
FROM processed
GROUP BY has_any_major_award;

```

Consulta para guardar el resultado en S3:

```

UNLOAD (
  SELECT
    has_any_major_award,
    COUNT(*) AS total_songs,
    AVG(duration_ms) AS avg_duration_ms,
    ROUND(AVG(duration_ms) / 1000, 2) AS avg_duration_seconds,

```

```

ROUND(AVG(duration_ms) / 60000, 2) AS avg_duration_minutes
FROM processed
GROUP BY has_any_major_award
)
TO 's3://datalake-agijonc-2026/analytics/query_03/'
WITH (
  format = 'PARQUET'
);

```

7.2 EXPLICACIÓN DE RESULTADOS

Las consultas anteriores permiten obtener una visión analítica del comportamiento de la música premiada y su evolución temporal.

7.2.1 Interpretación de la Consulta 1

Los resultados obtenidos muestran que las canciones premiadas presentan, de media, valores superiores en danceability, energy y valence respecto a las canciones no premiadas. Por el contrario, el tempo medio es prácticamente idéntico en ambos grupos, por lo que no parece ser un factor diferencial.

En conjunto, estos resultados sugieren que las canciones premiadas tienden a ser más bailables, ligeramente más enérgicas y con un carácter emocional más positivo.

7.2.2 Interpretación de la Consulta 2

Los resultados obtenidos muestran una evolución clara de las características musicales a lo largo del tiempo.

En términos generales, la danceability aumenta progresivamente desde valores bajos en los años 50, lo que sugiere una mayor orientación de la música reciente hacia ritmos más accesibles y bailables.

La variable energy también crece de forma notable, lo que indica una intensificación del sonido y de la producción musical.

Por el contrario, la acousticness desciende de manera sostenida, lo que refleja una menor presencia de elementos acústicos en favor de producciones más digitales.

En cuanto a valence se aprecia una ligera tendencia descendente en las últimas décadas.

En conjunto, estos resultados muestran que la música ha evolucionado hacia estilos más enérgicos, bailables y menos acústicos.

7.2.3 Interpretación de la Consulta 3

Los resultados muestran que la duración media de las canciones premiadas y no premiadas es prácticamente idéntica.

La diferencia entre ambos grupos es de apenas algo más de un segundo, por lo que no puede considerarse significativa.

En consecuencia, no se observa una relación clara entre la duración de las canciones y el hecho de recibir premios musicales, lo que sugiere que esta variable no actúa como un factor diferencial en el reconocimiento de la industria.

8 CONCLUSIONES

En este apartado se resumen los principales resultados obtenidos a lo largo del proyecto, así como posibles mejoras que podrían aplicarse al pipeline de datos.

8.1 HALLAZGOS PRINCIPALES

A partir del análisis realizado sobre el dataset integrado, se pueden destacar los siguientes hallazgos:

- Las canciones premiadas presentan, de media, valores superiores en danceability, energy y valence, lo que sugiere que la música más reconocida tiende a ser más accesible, enérgica y emocionalmente positiva.
- El tempo no muestra diferencias significativas entre canciones premiadas y no premiadas, por lo que no parece ser un factor determinante en el reconocimiento musical.
- La evolución temporal muestra una clara tendencia hacia una música más bailable y energética, junto con una reducción progresiva de la acousticness, lo que refleja el paso hacia producciones más digitales.
- El volumen de canciones disponibles aumenta significativamente en años recientes, lo que evidencia el crecimiento de plataformas de streaming y la disponibilidad de datos.
- La duración de las canciones no presenta diferencias relevantes entre canciones premiadas y no premiadas, por lo que no puede considerarse un factor diferencial.

En conjunto, estos resultados muestran que ciertas características musicales sí están asociadas al reconocimiento en premios, mientras que otras variables no tienen un impacto significativo.

8.2 POSIBLES MEJORAS DEL PIPELINE

Aunque el pipeline implementado cumple con los objetivos planteados, existen varias mejoras que podrían aplicarse en futuras versiones:

- Mejora en la integración de datos: utilizar técnicas más avanzadas de matching (por ejemplo, fuzzy matching) para mejorar la unión entre datasets y reducir errores derivados de coincidencias textuales.
- Gestión avanzada de datos nulos: aplicar estrategias más sofisticadas para el tratamiento de valores faltantes, especialmente en variables clave.
- Automatización del pipeline: integrar el flujo completo mediante servicios como AWS Step Functions o programar ejecuciones periódicas del Glue Job.
- Optimización del particionado: añadir nuevas particiones (por ejemplo, por artista o década) para mejorar el rendimiento en consultas más específicas.
- Incorporación de nuevas fuentes de datos: añadir información adicional como popularidad, reproducciones o datos de redes sociales para enriquecer el análisis.
- Visualización de datos: integrar herramientas como Amazon QuickSight o Power BI para crear dashboards interactivos basados en la capa analytics/.

Estas mejoras permitirían evolucionar el proyecto hacia una solución más robusta, escalable y orientada a entornos reales de análisis de datos.